

# Kernel ERA

## Full Simulation Results Walkthrough

- ✓ *24 conditions × 200 replications = 4,800 tasks (all completed)*
- ✓ *Content: Design → Methods → Data → Summary → Results*

### Overall Summary:

Kernel ERA는 truth가 linear에서 벗어날수록 예측·component recovery에서 Linear ERA를 능가하며, 그 이득은 **(a) nonlinear representation**과 **(b) high-dimensional low-signal에서의 regularized stabilization**이라는 두 개의 서로 다른 mechanism으로 분해 됨. 그리고 이 결론은 드물게 나타난 estimation instability를 배제해도 그대로 유지

PART 1

# Simulation Design & Methods

# 1.1 Conditions

$3 \times 2 \times 2 \times 2 = 24$  conditions,  $\times 200$  Monte Carlo replications  $\rightarrow 4,800$  tasks

| Factor                              | Levels                     | 의미                                 |
|-------------------------------------|----------------------------|------------------------------------|
| Truth (data-generating)             | linear / mixed / nonlinear | representation advantage를 test하는 축 |
| N (train)                           | 150 / 300                  | small vs. moderate sample          |
| P <sub>k</sub> (predictors per set) | 5 / 20                     | low vs. high dimensional           |
| Target R <sup>2</sup>               | .30 / .60                  | low vs. high signal                |

- predictor sets 3개 (n\_sets = 3), within-set correlation  $\rho = 0.4$ , between-set  $\rho = 0.1$ , nonlinearity strength 0.35로 고정
- 각 replication마다 독립적인 test sample 1,000개로 out-of-sample 성능 평가

## 1.2 세 가지 Truth의 의미

- **Linear truth:** 세계의 predictor set 모두 linear하게 outcome에 기여 → Kernel이 이길 이유가 원칙적으로 없음. Sanity check / null baseline
- **Mixed truth:** 일부 predictor set 은 linear, 일부는 nonlinear. 현실적으로 가장 흔한 상황 → "Kernel이 nonlinear set에서만 선택적으로 이긴다"를 보여줄 수 있음
- **Nonlinear truth:** 세 predictor set 모두 nonlinear structure → kernel representation advantage가 최대로 드러나는 best case

설계 포인트: predictor Set 2에 quadratic/interaction structure를 실어둠 → component 결과에서 Set 2의 이득이 일관되게 가장 큼. 우연이 아니라 심어놓은 설계이므로 "해석 가능한 결과"

## 1.3 Kernel ERA Model Fitting

- Gaussian kernel, denominator convention  $2\sigma^2$
- RKHS ridge penalty
- divisor-based component normalization
- predictor set 전체에 걸쳐 shared  $\lambda$ , shared  $\sigma$  (predictor set 별로 따로 tuning하지 않음)
- 5-fold CV로 tuning, candidate는 모든 fold가 수렴했을 때만 eligible (convergence-eligibility rule)
- final fit은 three-start, 실패해도 자동 fallback 없음 — 실패는 실패로 기록

## 1.4 Prediction Protocol & Stability 정의

### Prediction protocol (out-of-sample generalization 보증)

- training-only standardization (test 정보 누출 방지)
- test-to-training cross-kernel, training-centered kernel centering
- 독립 test sample 1,000 (각 replication마다 독립적인 test sample 1,000개로 out-of-sample 성능 평가)

### Stability (operational definitions)

- final nonconvergence: final three-start fit이 수렴 실패
- interpolation threshold:  $FIT_{train} > .98$  (train에 거의 완전히 fit  $\rightarrow$  overfitting/degenerate 신호)
- stable replication: final fit이 수렴 AND interpolating하지 않음
- 분석 표본 2가지: (1) all operational outputs — primary, (2) kernel-stable replications only — sensitivity check

## 1.5 Manuscript-Ready CSV 파일 (Uploaded on Github)

| 파일                                         | Granularity                                     | 담고 있는 것                                                                                                                                                                 |
|--------------------------------------------|-------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>master_results_by_condition</b>         | 24 conditions<br>(1행 = 1조건)                     | prediction( $\Delta R^2$ , win rate, MSE reduction, train-test gap), stability, tuning(CV exclusion, boundary, median $\lambda \cdot \sigma$ ), CI-MCSE 전부 — primary 파일 |
| <b>component_master_by_condition_set</b>   | $24 \times 3$ set = 72행                         | set별 $\Delta$ component correlation·RMSE, win rate, coverage                                                                                                            |
| <b>aggregate_prediction_by_scenario</b>    | 3 scenarios                                     | $\Delta R^2$ 등을 truth별로 평균                                                                                                                                              |
| <b>aggregate_component_by_scenario_set</b> | $3 \times 3 = 9$ 행                              | $\Delta$ component를 truth $\times$ set으로 평균                                                                                                                             |
| <b>operational_stability_by_design</b>     | 8 design cells<br>( $N \times P_k \times R^2$ ) | cell별 stable / nonconv / interp / CV-exclusion / boundary rate                                                                                                          |

PART 2

# Overall Summary



## (1) Pipeline은 computationally clean

- expected 4,800 = selected 4,800, task\_error\_rows = 0, 모든 selected CV candidate eligible, 모든 summary object 생성

*All 4,800 tasks completed successfully, with no task-level errors and no missing selected-model summaries.*

## (2) 예상보다 (pilot에서 예측했던 것보다) 훨씬 안정적

- 걱정했던 conditions 7–9의 catastrophic instability는 실현되지 않음
- Nonconvergence는 딱 3개 조건(7, 8, 11), 각각 3.0% / 1.5% / 0.5%. interpolation은 24개 조건 전부 0**
- "generally stable, with limited nonconvergence in the most difficult conditions"

| Condition | Scenario | $N$ | $P_k$ | Target $R^2$ | Nonconvergence rate | Stable rate |
|-----------|----------|-----|-------|--------------|---------------------|-------------|
| 7         | linear   | 150 | 20    | .30          | .030                | .970        |
| 8         | mixed    | 150 | 20    | .30          | .015                | .985        |
| 11        | mixed    | 300 | 20    | .30          | .005                | .995        |

### (3) Prediction Story

$\Delta R^2 = R^2(\text{Kernel}) - R^2(\text{Linear})$ , all operational outputs 기준

| Truth     | mean $\Delta R^2$ (all) | Kernel win rate | mean MSE reduction |
|-----------|-------------------------|-----------------|--------------------|
| Linear    | <b>+0.029</b>           | 0.56            | 0.023              |
| Mixed     | <b>+0.151</b>           | 0.94            | 0.159              |
| Nonlinear | <b>+0.248</b>           | 0.99            | 0.219              |

- 세 지표( $\Delta R^2$ , win rate, MSE reduction) 모두 linear  $\rightarrow$  mixed  $\rightarrow$  nonlinear로 monotonic 증가 — 깨끗한 dose-response
  - ✓ Linear truth에서는 평균적으로 작은 차이; Mixed truth에서는 Kernel ERA의 뚜렷한 이점; Fully nonlinear truth에서는 더 큰 이점; Kernel win rate도 nonlinear condition에서 거의 1에 가까움.
- 눈에 걸리는 지점: linear truth의 **+0.029**.
  - ✓ 원래 예상은 "0 근처 또는 약간 음수"였는데 약간 positive  $\rightarrow$  이걸 자세히 보면 주로  $P_k=20$ ,  $N=150$ ,  $R^2=.30$  low-signal condition 때문

# Results in detail: Research Questions 1–5

정상성(Q1) → 효익(Q2) → 메커니즘(Q3) → 한계(Q4) → 견고성(Q5)

## RQ1. Does Kernel ERA behave appropriately under linear truth? (Sanity Check)

질문의 목적: Kernel이 overfitting으로 이기는 게 아님을 확인 — linear truth에서 크게 이기면 안 됨

### Summary

linear truth를  $P_k$ 로 쪼개면 다른 그림:

- p.13:  $P_k = 5$  (저차원): 전부 살짝 음수 — sanity check okay
- p.14:  $P_k = 20$  (고차원): condition 7 ( $P_k=20$ ,  $N=150$ ,  $R^2=.30$  low-signal condition) — stabilization mechanism  
이 처음 노출되는 지점

## $P_k = 5$ (저차원):

전부 살짝 음수, win rate < 0.5 — "linear truth 에서 nonlinear method 가 굳이 이길 필요 없다"

E.g.,:

| Cond | N   | $R^2$ | $\Delta R^2$ | win rate |
|------|-----|-------|--------------|----------|
| 1    | 150 | .30   | -0.014       | 0.33     |
| 4    | 300 | .30   | -0.004       | 0.37     |
| 13   | 150 | .60   | -0.005       | 0.38     |
| 16   | 300 | .60   | -0.002       | 0.33     |

- 네 조건 모두  $\Delta R^2 < 0$ , win rate < 0.5 — Kernel이 유연성 비용을 약간 치르지만 손실은 미미
- 저차원 linear에서는 CV + RKHS penalty가 필요하지 않아 Linear ERA(correctly specified)가 근소 우세

## $P_k = 20$ (고차원):

*In high-dimensional, low-signal settings, Kernel ERA may also act as a strongly regularized supervised component method, reducing the train–test discrepancy relative to Linear ERA.*

| Cond | N   | $R^2$ | $\Delta R^2$ | win rate | Kernel gap | Linear gap |
|------|-----|-------|--------------|----------|------------|------------|
| 7    | 150 | .30   | +0.214       | 0.97     | 0.227      | 0.744      |
| 10   | 300 | .30   | +0.012       | 0.72     | 0.219      | 0.319      |
| 19   | 150 | .60   | +0.025       | 0.74     | 0.333      | 0.430      |
| 22   | 300 | .60   | +0.003       | 0.67     | 0.172      | 0.178      |

- **Cond 7에서.** Linear ERA가 이 조건에서 상당히 overfit 또는 unstable하게 작동했고, Kernel ERA는 CV와 RKHS penalty를 통해 더 안정적인 prediction을 한 것으로 보입니다.
  - ✓ train-test gap: Linear gap 0.744 vs Kernel gap 0.227. Linear ERA가 극악 조건(small-N × high-dim × low-signal)에서 심하게 overfit
  - ✓ Kernel은 CV + RKHS penalty 덕에 train에 덜 매달리고 test로 안정 이월 → nonlinear representation이 아니라 regularized stabilization

앞에 제시된 결과를 바탕으로: **Kernel ERA의 이득에는 두 가지 mechanism이 있을 수 있음을 알 수 있습니다.**

**1. Nonlinear representation advantage**

Mixed/nonlinear truth에서 nonlinear component를 더 잘 회복함.

→ RQ3의 component recovery로 증명

**2. Regularized stabilization advantage**

High-dimensional, low-signal condition에서 Linear ERA보다 train-test generalization이 더 안정적임.

→ RQ1의 condition 7이 증거

*Prediction만으로는 두 mechanism이 분리되지 않음.*

*representation 증거는 RQ3의 component recovery로 확정한다는 논리 흐름*

## RQ2. Does Kernel ERA improve prediction when the truth is nonlinear? (핵심 요약)

YES: 세 지표 모두 *monotonic*

- ✓ The predictive advantage of Kernel ERA increased monotonically as the data-generating mechanism departed from linearity, in  $\Delta R^2$ , win rate, and MSE reduction alike.

| Truth     | mean $\Delta R^2$ | win rate | MSE reduction |
|-----------|-------------------|----------|---------------|
| Linear    | +0.029            | 0.56     | 0.023         |
| Mixed     | +0.151            | 0.94     | 0.159         |
| Nonlinear | +0.248            | 0.99     | 0.219         |

- Condition 수준에서도 압도적:
  - ✓ cond 9 (nonlinear,150,20,.30):  $\Delta R^2$  +0.486
  - ✓ cond 21 (nonlinear,150,20,.60):  $\Delta R^2$  +0.444
- nonlinear 8개 조건 중 win rate 1.00 다수

- 주의: nonlinear truth의 이득 중 일부(특히  $P_k=20$ )도 stabilization과 섞여 있음.
  - ✓ "prediction gain 전부가 representation 때문"이라고 말하지 말 것 — representation 증거는 RQ3로 확정




# Figure 1. Prediction Advantage of Kernel ERA over Linear ERA

$\Delta R^2 = R^2(\text{Kernel}) - R^2(\text{Linear})$ , by truth  $\times P_k \times R^2 \times N$  — all operational outputs

Prediction advantage of Kernel ERA over Linear ERA

$$\Delta R^2 = R^2_{\text{Kernel}} - R^2_{\text{Linear}}$$



Note: Points show Monte Carlo mean differences in test  $R^2$  between Kernel ERA and Linear ERA across 200 replications. Error bars represent Monte Carlo 95% confidence intervals for the mean difference.

- truth가 linear  $\rightarrow$  mixed  $\rightarrow$  nonlinear로 갈수록  $\Delta R^2$ 가 monotonic 증가 (모든 panel에서 반복)
- $P_k=5$  linear:  $\Delta R^2 \approx 0$  또는 약간 음수 — 깨끗한 sanity check
- $P_k=20, R^2=.30$ , linear,  $N=150$ :  $\Delta R^2 \approx +0.21$ 로 튀어 오름  $\rightarrow$  condition 7, stabilization의 시각적 증거
- $N=300(\blacktriangle)$ 이  $N=150(\bullet)$ 보다 대체로 낮음 — 표본이 커지면 Linear ERA도 회복하므로 상대 이득 축소

### RQ3. Does Kernel ERA recover nonlinear domain components better? (Mechanism 증명)

전체 operational outputs 기준 평균  $\Delta$  component correlation은 다음과 같습니다.

$$\Delta\text{cor} = \text{cor}(\hat{f}_k^{\text{Kernel}}, f_k^{\text{true}}) - \text{cor}(\hat{f}_k^{\text{Linear}}, f_k^{\text{true}}).$$

| Truth     | Mean $\Delta$ component correlation | Mean Kernel component win rate |
|-----------|-------------------------------------|--------------------------------|
| Linear    | -0.024                              | .431                           |
| Mixed     | +0.191                              | .691                           |
| Nonlinear | +0.285                              | .954                           |

- *Prediction은 stabilization으로도 오르지만, true component와의 correlation은 실제로 구조를 잡아야만 오름*
  - ✓ Linear truth에서는 Linear ERA가 component recovery에서 약간 우세.
  - ✓ Mixed truth에서는 Kernel ERA가 평균적으로 더 좋음.
  - ✓ Nonlinear truth에서는 Kernel ERA가 확실히 좋음.
- (다음 페이지) 특히 **predictor set**별로 보면 story가 더 명확

### RQ3. Does Kernel ERA recover nonlinear domain components better? (Mechanism 증명)

Kernel은 무차별적이 아니라 nonlinear structure가 있는 predictor set에서만 선택적으로 이김

- ✓ Prediction gains were concentrated in precisely the predictor sets carrying quadratic/interaction structure; under linear truth, Kernel ERA showed no component-recovery advantage.
- ✓ Kernel ERA의 장점이 단순 prediction gain이 아니라 **true nonlinear domain component recovery**와 연결된다는 점을 보여줄 수 있습니다.

#### Mixed truth

| Set          | $\Delta\text{cor}$ | win  |
|--------------|--------------------|------|
| 1 (linear)   | -0.066             | 0.21 |
| 2 (quad/int) | +0.469             | 0.89 |
| 3 (mild NL)  | +0.169             | 0.97 |

#### Nonlinear truth

| Set | $\Delta\text{cor}$ | win  |
|-----|--------------------|------|
| 1   | +0.172             | 0.95 |
| 2   | +0.490             | 0.95 |
| 3   | +0.192             | 0.97 |


- mixed truth에서 Kernel은 nonlinear set(2,3)에서만 이기고 linear set(1)에서는 오히려 짐 — 무차별적이지 않다는 설득력 있는 증거
- Predictor Set 2가 두 truth 모두에서 최대 이득(+0.469, +0.490) — 우리가 Set 2에 quadratic/interaction을 심은 설계와 정확히 대응

## Figure 2. Component Recovery Advantage by True Functional Form

$$\Delta cor = cor(\hat{f}_{Kernel}, f_{true}) - cor(\hat{f}_{Linear}, f_{true}), \text{ predictor set 별}$$

Component recovery advantage by true functional form

$$\Delta cor = cor(\hat{f}_{Kernel}, f_{true}) - cor(\hat{f}_{Linear}, f_{true})$$




- Linear truth: 세 set 모두  $\Delta cor$  음수 — Kernel이 prediction으로는 이겨도(cond 7) component recovery로는 못 이김 → 그 이득이 representation이 아니라 stabilization이었음을 설명
- Mixed truth: Set 1(linear)만 음수, Set 2(quad/interaction) +0.469로 압도 — 무차별적이 아니라 구조가 있는 곳에서만 선택적으로 이김
- Nonlinear truth: 세 set 모두 양수, Set 2가 +0.490으로 최대 — Set 2에 quad/interaction을 심은 설계와 정확히 대응

## Figure 2b. Component Recovery by Design Condition

$truth \times R^2 \times P_k \times N$  전 조건에서 set 별  $\Delta cor$  — Figure 2 패턴의 robustness 확인

Component recovery by design condition



- Set 2 우위가 mixed·nonlinear의 모든 design cell에서 반복 — 특정 조건의 우연이 아님
- Linear truth(맨 윗줄)는 전 조건에서 0 근처 또는 음수 — 예외 없음
- Mixed truth의 Set 1은 일관되게 음수 — 선택적 승리 패턴이 조건에 걸쳐 안정적
- N=300(▲)이 N=150(●)보다 대체로 큰  $\Delta cor$  — 표본이 크면 nonlinear 구조를 더 잘 회복

이 그림은 "Figure 2에서 말하는 패턴이 전 조건에서 유지된다"는 근거로 만들었음

## RQ4. When does Kernel ERA become unstable?

불안정성은 매우 국소적

✓ final nonconvergence rate; interpolation rate; stable estimation rate; train–test fit gap; boundary tuning rate

- Nonconvergence는 세 조건뿐

| Cond | Scenario | N   | $P_k$ | $R^2$ | nonconv | stable |
|------|----------|-----|-------|-------|---------|--------|
| 7    | linear   | 150 | 20    | .30   | 3.0%    | 97.0%  |
| 8    | mixed    | 150 | 20    | .30   | 1.5%    | 98.5%  |
| 11   | mixed    | 300 | 20    | .30   | 0.5%    | 99.5%  |

- interpolation은 24개 조건 전부 0 (final\_interpolation\_rate = 0)

✓ *The estimator was generally stable under the final tuning specification, with limited nonconvergence concentrated in the most difficult low-signal, higher-dimensional, small-sample condition, and with no near-interpolation observed in any condition.*

## RQ4. When does Kernel ERA become unstable?

- 범인은 *high-dimension 자체*가 아니라 "*작은  $N \times$  고차원  $\times$  낮은 signal*"의 교집합

| N           | $P_k$ | $R^2$ | mean stable  | mean nonconv | mean CV exclusion |
|-------------|-------|-------|--------------|--------------|-------------------|
| 150         | 20    | .30   | <b>0.985</b> | <b>0.015</b> | <b>0.643</b>      |
| 300         | 20    | .30   | 0.998        | 0.002        | 0.382             |
| 150         | 20    | .60   | <b>1.000</b> | <b>0.000</b> | 0.265             |
| 나머지 5 cells |       |       | <b>1.000</b> | <b>0.000</b> | $\leq 0.077$      |

- 같은  $P_k=20$ 이어도 signal이  $R^2=.60$ 으로 오르면 nonconvergence가 0으로 떨어짐 — 통계적으로 완전히 말이 되는 결과이고 해석하기 좋음

## RQ4. When does Kernel ERA become unstable?

### Tuning Operating Characteristics

*Tuning 찌릿샬 —잡 줘핍 평 꺽곳농 됩 —줍업슬느닛: CV exclusion & boundary concentration*

#### 1. CV minimum exclusion이 $P_k=20, R^2=.30$ 에서 큼 (N=150: 64%, N=300: 38%)

- 평균적으로:

| $P_k$ | Target $R^2$ | Mean unrestricted minimum exclusion rate |
|-------|--------------|------------------------------------------|
| 5     | .30          | .041                                     |
| 5     | .60          | .006                                     |
| 20    | .30          | .512                                     |
| 20    | .60          | .203                                     |

- ✓ high-dimensional low-signal 조건에서는 nominally best CV MSE를 가진 candidate가 fold-level nonconvergence 때문에 자주 제외되었습니다.
- ✓ The convergence-eligibility rule was especially consequential in the  $P_k = 20, R^2 = .30$  conditions, where the unrestricted CV minimum was frequently excluded due to fold-level nonconvergence. This indicates that the most difficult conditions induced unstable candidate solutions even though the selected eligible models generally produced stable final fits.



## RQ4. When does Kernel ERA become unstable?

### Tuning Operating Characteristics

*Tuning 쪽에서 가장 중요한 결과는 두 가지였습니다: CV exclusion & boundary concentration*

#### 2. Boundary concentration flag가 19/24 condition에서 TRUE

- boundary는 무조건 나쁜 게 아닐 수 있음: smoother 선호 또는, 어려운 조건의 upper- $\lambda$ 는 강한 regularization 신호. 예를 들어:
  - ✓ Linear truth,  $P_k = 5$ :  $\sigma$  upper boundary가 자주 선택됨.
    - ✓ 이는 smoother/near-linear representation을 선호한다는 점에서 자연스럽습니다.
  - ✓ Nonlinear and  $P_k = 20$ :  $\lambda$  upper boundary가 자주 선택됨.
    - ✓ 어려운 조건에서 강한 regularization이 필요하다는 신호일 수 있습니다.

선제 대응 필요?

→ Option A(몇 개 조건만 expanded grid로 30–50 rep targeted sensitivity를 Supplement 예)


→ Option B(limitation으로 명시).

## RQ4. When does Kernel ERA become unstable?

### Figure 3. Operating Characteristics and Tuning Pressure

Stable fit · nonconvergence · interpolation · CV exclusion · boundary — 전 조건

Operating characteristics and tuning pressure




- Stable final fit: 대부분 100%. 97–98%로 떨어진 유일한 지점이  $P_k=20 \cdot R^2=.30$  panel
- Final nonconvergence:  $P_k=20 \cdot R^2=.30$  panel에서만 0이 아님 (최대 3%) — 나머지 전부 0
- Final interpolation: 24개 조건 전부 정확히 0%
- CV minimum excluded:  $P_k=20 \cdot R^2=.30$ 에서 40–60%대로 급등 — fold-level nonconvergence로 nominal best가 자주 탈락

## RQ4. When does Kernel ERA become unstable?

### Figure 3b. Compact Summary of Stability and Tuning Pressure

8개 design cell ( $N \times P_k \times R^2$ )로 집계, truth 조건에 걸친 평균 rate

Compact summary of stability and tuning pressure



- Stable final fit: 8개 cell 중  $N=150 \cdot P_k=20 \cdot R^2=.30$  하나만 100% 미만 — 불안정성의 완벽한 국소화
- CV minimum excluded: 같은 cell에서 64%로 최대,  $N=300 \cdot P_k=20 \cdot R^2=.30$ 이 38%로 그 다음
- 같은  $P_k=20$ 이어도  $R^2$ 가 .60으로 오르면 CV exclusion이 26%로 급락 — 범인은 high-dim 자체가 아니라 low-signal과의 교집합
- Any tuning boundary: 특정 cell에 국한되지 않고 전반적으로 높음 — stability와는 별개의 이슈로 다뤄야 함

## RQ5. Are the results robust to excluding nonstable Kernel ERA fits? (Robustness)

*all-operational과 stable-only가 사실상 동일 – 소수점 셋째 자리까지 같음*

| Truth     | $\Delta R^2$ (all) | $\Delta R^2$ (stable) |
|-----------|--------------------|-----------------------|
| Linear    | +0.02858           | +0.02857              |
| Mixed     | +0.15051           | +0.15071              |
| Nonlinear | +0.24833           | +0.24833              |


- nonconvergence가 3개 조건에서 최대 3%뿐이고 interpolation이 0이니, 뺄 게 거의 없음. stable-only에서 n이 줄어드는 조건도 7·8·11 셋뿐
- component 쪽도 all vs stable 차이가 소수점 넷째 자리 수준 (예: mixed Set 2 +0.469195 vs +0.469599)

- *The primary conclusions were evaluated both using all operational outputs and conditionally among replications in which the final Kernel ERA fit converged and did not exceed the interpolation threshold.*
- *Because nonstable final fits were rare and no interpolation was observed, all-operational and stable-only summaries led to essentially identical substantive conclusions. We report all-operational as primary and stable-only as a sensitivity check.*

# Figure 1b. All-Operational vs. Stable-Only Summaries

두 분석 표본의  $\Delta R^2$ 를 조건별로 대조 — 점선은  $y = x$  (완전 일치선)

All-operational and stable-only summaries give the same conclusions



- 모든 점이  $y = x$  대각선 위에 정확히 놓임 — 세 truth 조건 전부
- 불안정 fit을 배제해도  $\Delta R^2$ 가 사실상 변하지 않음
- 점 크기(stable rate 0.97–1.00)가 작은 조건조차 대각선을 벗어나지 않음 — 배제할 replication이 애초에 거의 없기 때문
- → all-operational을 primary, stable-only를 sensitivity check로 보고하는 근거

# Synthesis

- 1. Prediction  $\Delta R^2$  (이득): linear +0.029  $\rightarrow$  mixed +0.151  $\rightarrow$  nonlinear +0.248, monotonic
- 2. Train-test gap (stabilization 증거): cond 7에서 Kernel 0.227 vs Linear 0.744
- 3. Component recovery (representation 증거): linear -0.024, mixed +0.191, nonlinear +0.285; Set 2에서 선택적 우위
- 4. Design-cell stability: 불안정성은  $N=150 \times P_k=20 \times R^2=.30$  cell 하나에 집중, interpolation 0

# 논의할 사항

- Any feedback?
- More simulations?
- Results용 표/그림 정리
- Boundary concentration 대응: Option A(targeted sensitivity, 30–50 rep, Supplement) vs Option B(limitation 명시)