

Kernel ERA

R Implementation & Simulation Update

현재 Kernel ERA Specification

- Gaussian kernel: $\kappa(\mathbf{x}, \mathbf{z}) = \exp(-\|\mathbf{x} - \mathbf{z}\|^2 / 2\sigma^2)$
- RKHS-norm ridge penalty: $\lambda \sum_k \alpha_k^\top K_k \alpha_k$
- 각 predictor set의 component는 divisor-N variance = 1이 되도록 정규화
- 현재 manuscript specification: 모든 predictor set에 공통된 하나의 λ 와 하나의 σ 사용

Training / Test 처리

- 모든 standardization은 training sample의 mean과 divisor-N SD를 사용
- Validation/test sample 자체의 mean이나 SD로 다시 표준화하지 않음
- Test prediction에는 test-to-training cross-kernel을 사용
- Cross-kernel centering 역시 training Gram matrix에서 얻은 centering quantities 사용

Tuning Procedure 결정 (1) — Primary Rule

- 5-fold cross-validation
- 모든 CV fold에서 완전히 수렴한 candidate만 eligible
- Eligible candidates 중 validation MSE가 최소인 (λ, σ) 선택

```
cv_selection = "minimum"  
cv_require_all_folds_converged = TRUE
```

~~**One-Standard-Error Rule**~~ *I initially examined a one-standard-error rule, but it tended to over-regularize the model because model complexity cannot be ordered cleanly through λ and σ simultaneously (기존 tie-breaking rule이 큰 λ 와 큰 σ 를 선호하면서 pilot에서 과도한 smoothing과 underfitting을 유발함). I therefore retained minimum validation error among candidates that converged in every CV fold as the primary tuning rule*

안정화된 Estimation Settings

- Final model에 3개의 starts 사용
 - 첫 start는 Linear ERA warm start
 - 나머지는 random starts
- 수렴한 solution 중 objective가 가장 좋은 것을 선택
- max_iter = 500, convergence 및 objective-change tolerance를 별도로 사용
- Spectral solver를 기본으로 사용하되, direct solver와의 algebraic equivalence를 unit test에서 확인

Pilot: 30-Replication Stability

(1) Convergence & Interpolation

- Final convergence rate: 모든 조건에서 100%
- Interpolation rate: 0%
- 선택된 candidate는 모두 5개 CV fold 전부에서 수렴

Pilot: 30-Replication Stability

(2) Kernel ERA vs. Linear ERA

Truth Condition	ΔR^2 (Kernel – Linear)	Kernel ERA Win Rate
Linear truth	≈ -0.0075	— (거의 동등, Linear가 소폭 우수)
Mixed linear/nonlinear truth	$\approx +0.069$	$\approx 96.7\%$
Fully nonlinear truth	$\approx +0.169$	$\approx 93.3\%$

- 패턴: truth가 선형이면 Kernel ERA가 크게 우수하지 않음 / 비선형성이 포함되면 이점이 나타남 / 비선형성이 강해질수록 이점이 커짐
- Component recovery에서도 mixed/nonlinear condition, 특히 quadratic 및 interaction 구조가 포함된 predictor set에서 Kernel ERA의 우위가 뚜렷했음

Bandwidth Grid를 Predictor Dimension에 맞게 조정

- Main design에는 predictor set당 $P_k = 5$ 와 20이 모두 포함됨
- Pilot에서 linear truth일 때 큰 σ 가 자주 선택되었는데, 동일한 절대값 σ 는 predictor dimension이 다르면 같은 의미를 갖지 않음
- **Scaling 방식:** $\sigma(P_k) = \sigma_{\text{base}} \times \sqrt{P_k / 5}$

	Grid values
$P_k = 5$	0.75, 1.5, 3, 6, 12, 24, 48, 96
$P_k = 20$	1.5, 3, 6, 12, 24, 48, 96, 192

Difficult Conditions에서의 Instability

- 작은 N , 상대적으로 높은 dimension, 약한 signal 조건에서 다음이 나타날 수 있음:
 - 비수렴 / near-interpolation / 큰 train-test gap / boundary tuning selection / replication 간 variability 증가
- 이를 Kernel ERA의 finite-sample limitation으로 보고하기로 결정

중요 원칙:

- Final fit이 비수렴했다고 해서 자동으로 next-best tuning combination으로 대체하지 않음
- Failure를 숨기기 위해 tuning grid를 사후적으로 계속 축소하지 않음
- Nonconvergence와 interpolation을 simulation outcome으로 보고
- Prediction 결과는 (1) all operational outputs, (2) converged & non-interpolating replications only — 두 방식으로 제시

Main Simulation Design

총 24 conditions (factorial design)

Factor	Levels
Truth	linear / mixed linear-nonlinear / fully nonlinear
Training sample size (N)	150 / 300
Predictors per set (P_k)	5 / 20
Target R^2	.30 / .60

- 공통 설정: predictor sets 3개 / independent test sample 1,000 / within-set correlation .40 / between-set correlation .10
- 200 Monte Carlo replications per condition
- 즉, 총 $24 \times 200 = 4,800$ condition-replication tasks

Pipeline Verification 결과

1-Replication End-to-End Check

- 24개 조건 모두 실행, task-level error 없음
- 모든 selected rows 생성, CV eligibility 정상
- All-operational 및 stable-only summaries 생성
- Paired prediction/component summaries 생성
- Pipeline integrity check 통과

10-replication pilot: numerical stability와 instability rates 를 추가 확인 → 현재 full simulation 실행 중

Collaborators 의견 요청 사항

1. Primary tuning rule

모든 CV fold에서 수렴한 candidate 중 minimum CV MSE를 선택하는 방식에 동의하는지

2. Instability reporting

Nonconvergence/interpolation을 substantive operating characteristic으로 보고하고, all-operational 및 stable-only 결과를 함께 제시하는 방식이 적절한지

3. Simulation design

현재 24-condition factorial design과 200 replications가 충분한지, 추가해야 할 조건이나 sensitivity analysis가 있는지